# 机器学习及应用实验报告

——WEKA API 的熟悉与应用

实验编号: 二

实验名称: WEKA API 的熟悉与应用

实验室 : 电光学院 105

姓名:刘嘉洋学号:1412620

班级 : 软件学院 14 级二班

实验日期: 2017年3月7日

至 : 2017年3月14日

评分教师 实验报告成绩

评分日期 年 月 日

## 一、实验目的

- 在 Eclipse 中进行 weka. jar 的配置
- 结合 weka-src. jar 及说明文档进行 API 的学习
- 回顾 WEKA 基本模块及应用
- 完成 Instances, Filters, Classifier, Evaluation 类的编程操作
- 对比分析常见分类器的表现结果
- 掌握便捷获取. arff 格式文件的技巧


# 二、实验环境

- macOS Sierra Version 10.12
- weka-3-8-1
- Eclipse Mars Release 4.5.0

# 三、实验报告

1. Instance 类 • 数据读取与统计输出 step1: 在 Eclipse 中新建 Java Project

step2: 导入 weka.jar 并配置源码路径指向 weka-src.jar,以便 API 查阅



step3: 新建类,调用 getFileInstance 方法指向 bank.arff 数据集,获取数据实例

Instances instances = getFileInstances(

"/Users/macdowell/Desktop/Professional Materials/3\_Junior\_S2/2\_MachineLearning/Lab/2\_WekaAPI/实验二 数据集/bank.arff");

## step4: [重要] 调用实例对象的 setClassIndex 方法,将最后一列设置为类别

// 注意:要首先设置类属性标签,不然会在调用numClasses()时报"UnassignedClassException"instances.setClassIndex(instances.numAttributes() - 1); // 设置最后一列为类别

step5: 调用对应方法,分别获取数据集样例数、属性数、类别数,并打印输出

```
System.out.println("样例数: " + instances.numInstances());
System.out.println("属性数: " + instances.numAttributes());
System.out.println("类别数: " + instances.numClasses());
```

step6: InstanceAssign 类控制台运行结果

样例数: 600 属性数: 11 类别数: 2

- 2. Filters 类 属性操作
- 2.1 Discretize 类 离散化

step1: 新建类,重复上述操作完成数据实例初始化 (bank.arff)

step2: 自定义属性离散化方法 discretizeAttribute

其中: option 取"-R"表示对整列进行离散化,并在紧接着的 option 指定目标属性列号,列号从1开始,多列则标号间以;间隔

```
* 属性离散化方法
 * @param instances 数据实例
 * @throws Exception
public static void discretizeAttribute(Instances instances) throws Exception {
    // 离散化第1、4个属性
    Discretize discretize = new Discretize();
    String[] options = new String[2];
    options[0] = "-R"; // Specifies list of columns to Discretize.
    options[1] = "1,4"; // 指定多列 中间以,间隔
    // options[2] = "-R"; // 这样的写法是不对的
    // options[3] = "4";
    discretize.setOptions(options);
    discretize.setInputFormat(instances);
    Instances newData = Filter.useFilter(instances, discretize);
    for (int i = 0; i < 20; i++) {
       // instance( i )是得到第i个样本
       System.out.println(newData.instance(i));
    }
}
```

#### step3: main 方法中调用 discretizeAttribute,控制台运行结果

## 2.2 Normalize 类 • 归一化

```
step4: 自定义属性归一化方法 normalizeAttribute
      其中:option 取"-T":归一区间的起始坐标
                  取"-S":归一区间的长度
      [注] Normalize 会自动归一化所有 numeric 类型的属性
     /**
      * 属性归一化方法
      * @param instances 数据实例
      * @throws Exception
     public static void normalizeAttribute(Instances instances) throws Exception {
         Normalize normalize = new Normalize();
         String[] options = new String[4];
         // 归一化所有numeric类型的属性
         // 归一区间设置为[-1,1]
         options[0] = "-T"; // The translation of the output range.
         options[1] = "-1"; // 从-1起始
         options[2] = "-S"; // The scaling factor for the output range.
         options[3] = "2"; // 跨度为2
         normalize.setOptions(options);
         normalize.setInputFormat(instances);
         Instances newData = Filter.useFilter(instances, normalize);
         for (int i = 0; i < 20; i++) {
             System.out.println(newData.instance(i));
     }
```

#### step5: main 方法中调用 normalizeAttribute, 控制台运行结果

```
0.22449, FEMALE, INNER_CITY, -0.568731, NO, 1, NO, NO, NO, YES
-0.102041, MALE, TOWN, -0.13721, YES, 3, YES, NO, YES, YES, NO
0.346939, FEMALE, INNER_CITY, -0.602133, YES, 0, YES, YES, YES, NO, NO
-0.795918, FEMALE, TOWN, -0.47136, YES, 3, NO, NO, YES, NO, NO
0.591837, FEMALE, RURAL, 0.567974, YES, 0, NO, YES, NO, NO, NO
0.591837, FEMALE, TOWN, 0.130685, YES, 2, NO, YES, YES, NO, YES
-0.836735, MALE, RURAL, -0.867064, NO, 0, NO, NO, YES, NO, YES
0.632653, MALE, TOWN, -0.314047, YES, 0, YES, YES, YES, NO, NO
-0.22449, FEMALE, SUBURBAN, -0.301737, YES, 2, YES, NO, NO, NO
0.469388, MALE, TOWN, -0.339324, YES, 2, YES, YES, YES, NO, NO
0.959184, FEMALE, TOWN, 0.885532, YES, 0, NO, YES, YES, NO, NO
0.387755, FEMALE, INNER_CITY, -0.255123, NO, 0, YES, YES, YES, YES, NO
0.061224, FEMALE, TOWN, -0.631027, YES, 1, NO, YES, YES, YES, YES
0.959184, FEMALE, TOWN, 0.727255, YES, 1, YES, YES, YES, YES, YES
-0.265306, MALE, RURAL, -0.50236, YES, 0, NO, YES, YES, YES, NO
-0.183673, FEMALE, INNER_CITY, -0.403678, YES, 0, YES, YES, YES, YES, NO
-0.22449, FEMALE, TOWN, -0.562406, YES, 2, NO, NO, NO, YES, NO
0.142857, FEMALE, SUBURBAN, 0.238965, YES, 0, NO, YES, NO, YES, NO
0.795918, FEMALE, INNER_CITY, -0.246506, YES, 0, NO, YES, NO, NO, YES
-0.469388, MALE, TOWN, -0.397459, YES, 0, YES, YES, YES, NO, NO
```

#### 2.3 Remove 类 • 删除

step6: 自定义属性删除方法 removeAttribute

其中: option 取"-R"表示对整列进行删除,并在紧接着的 option 指定目标属性列号,列号从1开始,多列则标号间以",间隔

[注] Remove 的删除只是将程序中处理的数据集进行过滤。并不会对.arff 进行改变

```
* 属性删除方法
 * @param instances 数据实例
 * @throws Exception
public static void removeAttribute(Instances instances) throws Exception {
   Remove remove = new Remove();
   String[] options = new String[2];
   // 删除第2、3个属性
   options[0] = "-R";
   options[1] = "2,3"; // 指定多列 中间以,间隔
   remove.setOptions(options);
   remove.setInputFormat(instances);
   Instances newData = Filter.useFilter(instances, remove);
   for (int i = 0; i < 20; i++) {
       System.out.println(newData.instance(i));
   }
}
```

step7: main 方法中调用 normalizeAttribute. 控制台运行结果

```
48,17546,NO,1,NO,NO,NO,NO,YES
40,30085.1,YES,3,YES,NO,YES,YES,NO
51,16575.4,YES,0,YES,YES,YES,NO,NO
23,20375.4,YES,3,NO,NO,YES,NO,NO
57,50576.3,YES,0,NO,YES,NO,NO,NO
57,37869.6,YES,2,NO,YES,YES,NO,YES
22,8877.07,NO,0,NO,NO,YES,NO,YES
58,24946.6,YES,0,YES,YES,YES,NO,NO
37,25304.3,YES,2,YES,NO,NO,NO,NO
54,24212.1,YES,2,YES,YES,YES,NO,NO
66,59803.9,YES,0,NO,YES,YES,NO,NO
52,26658.8,NO,0,YES,YES,YES,YES,NO
44,15735.8,YES,1,NO,YES,YES,YES,YES
66,55204.7,YES,1,YES,YES,YES,YES,YES
36,19474.6,YES,0,NO,YES,YES,YES,NO
38,22342.1,YES,0,YES,YES,YES,YES,NO
37,17729.8,YES,2,NO,NO,NO,YES,NO
46,41016,YES,0,NO,YES,NO,YES,NO
62,26909.2,YES,0,NO,YES,NO,NO,YES
31,22522.8,YES,0,YES,YES,YES,NO,NO
```

- 3. Classifier 类 分类器的使用与评估
- 3.1 10 折交叉验证的使用

step1: 新建类,重复上述操作完成数据实例初始化 (bank.arff)

step2: 自定义一致评估方法 unifiedEvaluation,提供给分类器对象统一的借口

```
/**
* 一致评估方法。评价当前数据集及分类器情况下在十折交叉认证中的正确率。
* @param instances 数据实例
* @param classifier 采用分类器
 * @throws Exception
private static void unifiedEvaluation(Instances instances, Classifier classifier) throws Exception {
   Evaluation eval = new Evaluation(instances);
   eval.crossValidateModel(classifier, instances, 10, new Random(1)); // 使用10折交叉认证
   System.out.println(1 - eval.errorRate()); // 正确率 = 1 - 错误率
7
```

#### step3: 分别定义分类器并调用 unifiedEvaluation 方法

### step4: ClassifierAssign1 类控制台运行结果

0.69	
使用SMO分类器 0.70833333333333333333333333333333333333	
使用J48分类器 0.91	
使用1NN分类器0.715000000000000001	

## step5: 在 WEKA 打开 bank.arff 数据集依次使用四种分类器,核对输出验证程序正确性

=== Stratified cross-validation === === Summary ===				=== Stratified Cross-Validation === === Summary ===		
Correctly Classified Instances	414	69	%	Correctly Classified Instances	425	70.8333 %
Incorrectly Classified Instances	186	31	%	Incorrectly Classified Instances	175	29.1667 %
Kappa statistic	0.3724			Kappa statistic	0.4062	
Mean absolute error	0.3773			Mean absolute error	0.2917	
Root mean squared error	0.4397			Root mean squared error	0.5401	
Relative absolute error	76.0306 %			Relative absolute error	58.7714 %	
Root relative squared error	88.2766 %			Root relative squared error	108.4169 %	
Total Number of Instances	600			Total Number of Instances	600	
a. 朴素贝	八叶斯			b. SMO		
=== Stratified cross-validation ===				=== Stratified cross-validation ===		
=== Summary ===				=== Summary ===		
Correctly Classified Instances	546	91	%	Correctly Classified Instances	429	71.5 %
Incorrectly Classified Instances	54	9	%	Incorrectly Classified Instances	171	28.5 %
Kappa statistic	0.8178			Kappa statistic	0.4259	
Mean absolute error	0.1559			Mean absolute error	0.2858	
Root mean squared error	0.2903			Root mean squared error	0.5329	
Relative absolute error	31.4168 %			Relative absolute error	57.5879 %	
Root relative squared error	58.2815 %			Root relative squared error	106.9734 %	
Total Number of Instances	600			Total Number of Instances	600	
c. J48				d. 1NN		

图 1 WEKA 中四种分类器对 bank.arff 的表现结果

## 3.2 训练集与测试集的使用

step1: 新建类,分别对 U\_segmentation\_train.arff 训练集与 U\_segmentation\_tetst.arff 测试集进行数据实例初始化以及类别属性设置


```
String basedPath = "/Users/macdowell/Desktop/Professional Materials/3_Junior_S2/2_MachineLearning/Lab/2_WekaAPI/实验二 数据集/";
DataSource trainingSet=new DataSource( basedPath + "U_segmentation_train.arff");
Instances instancesTrain = trainingSet.getDataSet();
instancesTrain.setClassIndex(instancesTrain.numAttributes() - 1); // 设置最后一列为类别

DataSource testingSet = new DataSource( basedPath + "U_segmentation_test.arff");
Instances instanceTest = testingSet.getDataSet();
instanceTest.setClassIndex(instanceTest.numAttributes() - 1); // 设置最后一列为类别
```

step2: 自定义一致评估方法 unifiedEvaluation,提供给分类器对象统一的借口其中:buildClassifier 方法通过训练集训练出分类模型 evaluateModel 方法通过测试集测试所得分类模型

```
* 一致评估方法。评价当前数据训练集及分类器情况下在测试集中的正确率。
 * @param instancesTrain 数据训练实例
 * @param instancesTrain 数据测试实例
 * @param classifier 采用分类器
 * @throws Exception
private static void unifiedEvaluation(Instances instancesTrain, Instances instancesTest, Classifier classifier) throws Exception {
   classifier.buildClassifier(instancesTrain); // 通过训练集训练分类模型
   Evaluation eval = new Evaluation(instancesTrain);
   eval.evaluateModel(classifier, instancesTest); // 通过测试集测试分类模型 System.out.println(1 - eval.errorRate()); // 正确率 = 1 - 错误率
step3: ClassifierAssign2 类控制台运行结果
        -----使用朴素贝叶斯分类器--
        0.7995238095238095
        -----使用SMO分类器------
        0.8738095238095238
        -----使用J48分类器-----
        0.91
        -----使用1NN分类器-----
        0.9257142857142857
```

step4: 在 WEKA 输入同样的训练集和测试集使用四种分类器,核对输出验证程序正确性



=== Summary ===			=== Summary ===		
Correctly Classified Instances	1679	79.9524 %	Correctly Classified Instances	1835	87.381 %
Incorrectly Classified Instances	421	20.0476 %	Incorrectly Classified Instances	265	12.619 %
Kappa statistic	0.7661		Kappa statistic	0.8528	
Mean absolute error	0.0578		Mean absolute error	0.2065	
Root mean squared error	0.2298		Root mean squared error	0.3051	
Relative absolute error	23.5953 %		Relative absolute error	84.3333 %	
Root relative squared error	65.6684 %		Root relative squared error	87.18 %	
Total Number of Instances	2100		Total Number of Instances	2100	
a. 朴素.	贝叶斯		b. SM0	)	
=== Summary ===			=== Summary ===		
Correctly Classified Instances	1911	91 %	Correctly Classified Instances	1944	92.5714 %
Incorrectly Classified Instances	189	9 %	Incorrectly Classified Instances	156	7.4286 %
Kappa statistic			Kappa statistic	0.9133	
	0.895				
Mean absolute error	0.895 0.0308		Mean absolute error	0.0284	
Mean absolute error Root mean squared error			Mean absolute error Root mean squared error	0.0284 0.1438	
	0.0308		Mean absolute error	0.0284	
Root mean squared error Relative absolute error Root relative squared error	0.0308 0.1544		Mean absolute error Root mean squared error Relative absolute error Root relative squared error	0.0284 0.1438	
Root mean squared error Relative absolute error	0.0308 0.1544 12.558 %		Mean absolute error Root mean squared error Relative absolute error	0.0284 0.1438 11.6129 %	

图 2 WEKA 中四种分类器对 U\_segmentation 训练集与测试集的表现结果

## 4. .txt->.cvs->.arff 的转换

step1: 打开 sample.txt,将辅助说明删去,并使属性数值间以英文;;间隔

- 2017.3.1, 晴, 微风, 正午10摄氏度, 空气潮湿, 适合出行
- 2017.3.2,多云,无风,正午6摄氏度,空气干燥,适合出行
- 2017.3.3,下雨,微风,正午8摄氏度,空气潮湿,不适合出行
- 2017.3.4,晴,大风,正午12摄氏度,空气潮湿,适合出行
- 5 2017.3.5, 多云, 大风, 正午-3摄氏度, 空气干燥, 不适合出行

step2: 直接将文件后缀由.txt 改为.cvs



sample.csv

step3: 此时.cvs 文件使用 Excel 或 Numbers 可直接打开

[注] Excel 打开.cvs 文件可能会出现中文乱码的情况


原因:.cvs 文件默认为 ANSI 编码,如果.cvs 文件的编码方式为 utf-8、Unicode 等 方式时便会出现乱码

解决方法:用记事本等工具打开.cvs 文件、将其另存为并选择 ANSI 编码方式即可

Table 1

2017.3.1	晴	微风	正午10摄氏度	空气潮湿	适合出行
2017.3.2	多云	无风	正午6摄氏度	空气干燥	适合出行
2017.3.3	下雨	微风	正午8摄氏度	空气潮湿	不适合出行
2017.3.4	晴	大风	正午12摄氏度	空气潮湿	适合出行
2017.3.5	多云	大风	正午-3摄氏度	空气干燥	不适合出行





## step5: 使用 Sublime 等工具打开生成的 sample.arff 文件,验证格式正确性

## 5. KNN 分类器的比较与分析

step1: 在 Eclipse 工程中新建类,重复上述操作完成数据实例初始化 (bank.arff)

step2: 同样采用在上述 ClassifierAssign1 类中自定义的一致评估方法 unifiedEvaluation

#### step3: 构建分类器,使 K 分别取值 1、5、10、30

```
System.out.println("--
Classifier classifier1 = new IBk();
((IBk) classifier1).setKNN(1);
unifiedEvaluation(instances, classifier1);
System.out.println("\n----
Classifier classifier2 = new IBk();
((IBk) classifier2).setKNN(5);
unifiedEvaluation(instances, classifier2);
System.out.println("\n----
                                    ----K = 10-
Classifier classifier3 = new IBk();
((IBk) classifier3).setKNN(10);
unifiedEvaluation(instances, classifier3);
System.out.println("\n----
                                    ---K = 30-----");
Classifier classifier4 = new IBk();
((IBk) classifier4).setKNN(30):
unifiedEvaluation(instances, classifier4);
```

#### step4: KNNAssign 类控制台运行结果

0.71500000000000001	= 1
0.755	= 5
K 0.77833333333333333	= 10
K 0.76833333333333333	= 30

step5: 在 WEKA 打开 bank.arff 数据集使用 IBk 分类器将 K 依次取同样四种值,核对输出验证程序正确性




图 3 WEKA 中 IBk 分类器四种 K 取值时的表现结果

#### step6: 比较与分析


①首先尝试在程序中将 K 以 1 为间隔在[1,130]连续取值找寻变化趋势

## 其在控制台运行结果([31,110]区间段没有贴出)

```
K = 112, accuracy = 0.6833333333333333
K = 114, accuracy = 0.675
K = 115, accuracy = 0.6683333333333333
K = 116, accuracy = 0.681666666666666
K = 117, accuracy = 0.666666666666667
K = 118, accuracy = 0.6833333333333333
K = 119, accuracy = 0.666666666666667
K = 120, accuracy = 0.671666666666666
K = 122, accuracy = 0.665
K = 123, accuracy = 0.66166666666666
K = 124, accuracy = 0.665
K = 125, accuracy = 0.656666666666667
K = 126, accuracy = 0.666666666666667
K = 127, accuracy = 0.655
K = 128, accuracy = 0.65666666666667
K = 129, accuracy = 0.6533333333333333
K = 130, accuracy = 0.666666666666667
```

通过观察可以得知, 其准确率并没有标准的单调性, 在[0.665,0.79166]间波动, 在 K 取 [22,24]区间段达到峰值, 并在其后逐渐减小 (后测试将 K 取值区间扩大至[1,230]可确认 K 值继续增大后准确率保持着波动下降的趋势)

## ②回顾 KNN 算法



step1---初始化距离为最大值

step2---计算未知样本和每个训练样本的距离 dist

step3---得到目前 K 个最临近样本中的最大距离 maxdist

step4---如果 dist 小于 maxdist,则将该训练样本作为 K-最近邻样本

step5---重复步骤 2、3、4、直到未知样本和所有训练样本的距离都算完

step6---统计 K-最近邻样本中每个类标号出现的次数

step7---选择出现频率最大的类标号作为未知样本的类标号

#### ③个人理解

最优的 K 值是取决于数据集的,其取值一方面应尽量大以使得噪点不会干扰预测的准确率,同时也不应过大避免导致 K 值主导了 KNN 算法中的其他参数反而影响准确率。在有的参考资料上看到说 $\sqrt{data\_set\ size}$ 是推荐的取值,但我觉得在数据集规模适宜的情况下最稳妥的方式仍然是通过遍历结合交叉验证找寻到使预测准确率最高的 K 值。

# 四、写在最后

感谢卫金茂老师以及助教学长学姐对本次实验的细致指导和悉心解答。 因初期学习机器学习知识,报告中出现的理解偏差也望指正。

刘嘉洋 NKCS, 1412620 macdowellliu@163.com

2017.3.8